

1. 奇异值分解 (SVD)

Collected by Sizhe Zhou
2022. 4. 8.

1.1 奇异值分解的定义与性质

1.1.1 定义与定理

定义 1.1: $A \in \mathbb{R}^{m \times n}$, $A = U \Sigma V^T$

其中 U 为 m 阶 orthogonal matrix ($\mathbb{R}^{m \times m}$)

V 为 n 阶正交矩阵 ($\mathbb{R}^{n \times n}$)

Σ 是由降序排列的非负的 $m \times n$ 对角矩阵

s.t. $UU^T = I$, $VV^T = I$, $\Sigma = \text{diag}(6_1, 6_2, \dots, 6_p)$

$6_1 \geq 6_2 \geq \dots \geq 6_p \geq 0$, $p = \min(m, n)$

6_i 称为 A 的 singular value

U 的列向量称为 left singular vector

V 的列向量称为 right singular vector

(分解不唯一)

定理 1.1 (SVD 基本定理): $A \in \mathbb{R}^{m \times n}$, 如上的 SVD 存在
构造性证明: (假设 $m > n$)

(1) 确定 V 和 Σ :

$A^T A$ 为 n 阶实对称 $\Rightarrow A^T A$ 的 eigenvalues 为非负且存在 n 阶正交
实矩阵 V , s.t. $V^T (A^T A) V = \Lambda$ where Λ 为 n 阶对角, 其对角
元素由 $A^T A$ 的特征值组成

令 λ 是 $A^T A$ 的一个特征值, x 是对应特征向量, 则

$$\|Ax\|^2 = x^T A^T A x = \lambda x^T x = \lambda \|x\|^2$$

$$\Rightarrow \lambda = \frac{\|Ax\|^2}{\|x\|^2} \geq 0$$

可 assume V 的列排列使相应 eigen values 形成

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n \geq 0$$

then let $\sigma_j = \sqrt{\lambda_j}, j=1, 2, \dots, n$ (即 A 的奇异值)

设 $\text{rank}(A) = r, \Rightarrow \text{rank}(A^T A) = r$. 由于 $A^T A$ 为对称矩阵,
 $\text{rank}(A) = \# \text{positive } \lambda_i$.

$$\Rightarrow \lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0, \lambda_{r+1} = \lambda_{r+2} = \cdots = \lambda_n = 0$$

$$\text{对应: } \sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0, \sigma_{r+1} = \sigma_{r+2} = \cdots = \sigma_n = 0$$

令 $V_1 = [v_1 \ v_2 \ \cdots \ v_r] \quad V_2 = [v_{r+1} \ v_{r+2} \ \cdots \ v_n]$

v_i 为 λ_i 对应的特征向量

$$\Rightarrow V = [V_1 \ V_2] \text{ (即 } A \text{ 的 SVD 中的 } V)$$

令 $\Sigma_1 = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$

$m \times n$ 矩形对角阵 $\Sigma = \begin{bmatrix} \Sigma_1 & 0 \\ 0 & 0 \end{bmatrix}$ (即 A 的 SVD 中的 Σ)

$$A^T A v_j = 0, j=r+1, \dots, n$$

于是 $\text{span}(v_{r+1}, \dots, v_n) = \text{null space of } A^T A =: N(A^T A)$

而 $N(A^T A) = N(A) \Rightarrow v_{r+1}, \dots, v_n$ 构成 $N(A)$ 的标准正交基

$$\Rightarrow A V_2 = 0$$

由于 V 为正交矩阵,

$$I = V V^T = V_1 V_1^T + V_2 V_2^T$$

$$A = A I = A V_1 V_1^T + A V_2 V_2^T = A V_1 V_1^T$$

(2) 确定 U

$$\text{令 } u_j = \frac{1}{\sigma_j} Av_j, j=1, 2, \dots, r$$

$$U = [u_1 \ u_2 \ \dots \ u_r]$$

$$\text{则有 } Av_i = U_1 \Sigma_1$$

U_1 的列向量构成了一组标准正交集, 因为

$$u_i^T u_j = \left(\frac{1}{\sigma_i} v_i^T A^T \right) \left(\frac{1}{\sigma_j} Av_j \right)$$

$$= \frac{1}{\sigma_i \sigma_j} v_i^T (A^T A) v_j$$

$$= \frac{\sigma_j}{\sigma_i} v_i^T v_j = \delta_{ij}, i=1, 2, \dots, r; j=1, 2, \dots, r$$

由上可知, $u_1 \sim u_r$ 构成 $K(A)$ 的一组标准正交基

$$\dim K(A) = r, \dim K(A)^\perp = m-r.$$

令 $\{u_{r+1}, u_{r+2}, \dots, u_m\}$ 为 $N(A^T)$ 的一组标准正交基,

$$\text{并令 } U_2 = [u_{r+1} \ u_{r+2} \ \dots \ u_m]$$

$U = [U_1 \ U_2]$ 为 m 阶正交矩阵 (A 的 SVD 中的 U)

(3) 证明 $U \Sigma V^T = A$

$$U \Sigma V^T = [U_1 \ U_2] \begin{bmatrix} \Sigma_1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} V_1^T \\ V_2^T \end{bmatrix}$$

$$= U_1 \Sigma_1 V_1^T = AV_1 V_1^T = A$$

$\Rightarrow A$ 存在 SVD

1.1.2 紧奇异值分解与截断奇异值

1. 紧奇异值分解 \rightarrow 无损压缩

定义 1.2: $A \in \mathbb{R}^{m \times n}$, $\text{rank}(A) = r$, $[r \leq \min(m, n)]$

称 $U_r \Sigma_r V_r^T$ 为 A 的 compact SVD, $A = U_r \Sigma_r V_r^T$
 U_r 为 $m \times r$, V_r 为 $n \times r$, Σ_r 为 r 阶对角

(前 r 列 of U) (前 r 列 of V) (前 r 列 of Σ)

$\text{rank}(\Sigma_r) = r$ obviously

2. 截断奇异值分解 \rightarrow 有损压缩

定义 1.3: $A \in \mathbb{R}^{m \times n}$, $\text{rank}(A) = r$, $0 < k < r$,

$U_k \Sigma_k V_k^T$ 为 A 的 truncated SVD

$A \approx U_k \Sigma_k V_k^T$

U_k 为 $m \times k$, V_k 为 $n \times k$, Σ_k 为 k 阶对角

(前 k 列) (前 k 列) (前 k 列)

$\text{rank}(U_k \Sigma_k V_k^T) < r$

1.1.3 几何解释

• $A \in \mathbb{R}^{m \times n}$ 表示从 \mathbb{R}^n 到 \mathbb{R}^m 的线性变换

• 线性变换可分解为一个坐标系的旋转或反射变换

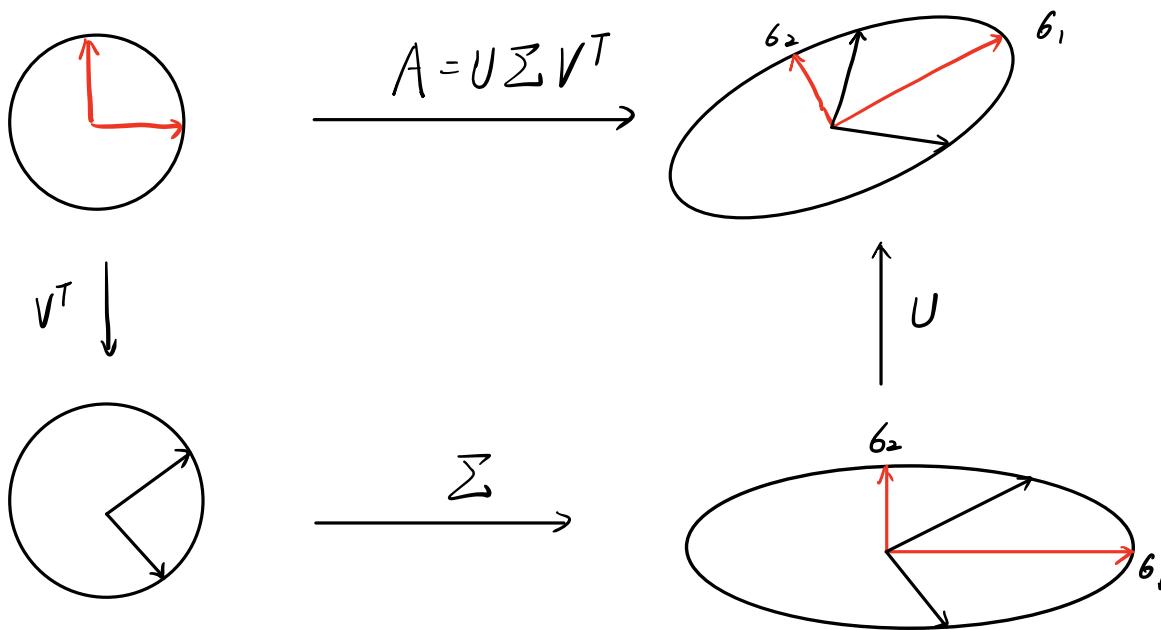
 | 一个坐标轴的缩放变换

 | 另一个坐标系的旋转或反射变换

• $v_1 \sim v_n$ 构成 \mathbb{R}^n 的标准正交基, 表示 \mathbb{R}^n 中正交坐标系的旋转或反射变换;

$u_1 \sim u_m$ 同理;

Σ 中 b_1, b_2, \dots, b_n 表示 \mathbb{R}^n 中原始正交坐标系坐标轴的 b_1, b_2, \dots, b_n 伸缩变换.



1.1.4 主要性质

(1) $A = U\Sigma V^T$, 则有

$$A^T A = V (\Sigma^T \Sigma) V^T$$

$$A A^T = U (\Sigma \Sigma^T) U^T$$

即 $A^T A$, $A A^T$ 的特征分解存在, 且可由 A 的 SVD 表示

V 的列向量为 $A^T A$ 的特征向量, U 的列向量为 $A A^T$ 的特征向量
 Σ 的奇异值是 $A^T A$ 和 $A A^T$ 的特征值的平方根

(2) $AV = U\Sigma$, 比较第 j 列,

$$\Rightarrow Av_j = b_j u_j, \quad j = 1, 2, \dots, n$$

$$\text{类似地, } A^T U = V \Sigma^T$$

$$\Rightarrow A^T u_j = b_j v_j, \quad j = 1, 2, \dots, n$$

$$A^T u_j = 0, \quad j = n+1, n+2, \dots, m$$

(3) 奇异值 b_1, b_2, \dots, b_n 唯一, 而 U, V 不唯一

(4) $\text{rank}(A) = \text{rank}(\Sigma) = \# \text{positive } b_i$ (包含重复)

(5) A 的 r 个右奇异向量 v_1, v_2, \dots, v_r 构成 $R(A^T)$ 的一组标准

正交基。

A 的 $n-r$ 个右奇异向量 $v_{r+1}, v_{r+2}, \dots, v_n$ 构成 $N(A)$ 的一组标准正交基

A 的 r 个左奇异向量 u_1, u_2, \dots, u_r 构成 $R(A)$ 的一组标准正交基。

A 的 $m-r$ 个左奇异向量 $u_{r+1}, u_{r+2}, \dots, u_m$ 构成 $N(A^T)$ 的一组标准正交基

1.2 奇异值分解的计算

(1) 首先求 $A^T A$ 的特征值与特征向量

$$W = A^T A$$

求解 $(W - \lambda I)x = 0$

将得到的特征值由大到小排列：

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

将 λ_i 代入特征方程求得对应特征向量

(2) 求 n 阶正交矩阵 V

将特征向量单位化，得到单位特征向量 v_1, v_2, \dots, v_n

构成 $V = [v_1 \ v_2 \ \dots \ v_n]$

(3) 求 $m \times n$ 对角矩阵 Σ

计算 A 的奇异值 $\sigma_i = \sqrt{\lambda_i}$, $i = 1, 2, \dots, n$

$\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n)$ 其余元素为 0

(4) 求 m 阶正交矩阵 U

对 A 的前 r 个正奇异值，令

$$u_j = \frac{1}{\sigma_j} A v_j, \quad j = 1, 2, \dots, r$$

得到 $U = [u_1 \ u_2 \ \dots \ u_r]$

求 A^T 的零空间的一组标准正交基 $\{u_{r+1}, u_{r+2}, \dots, u_m\}$

$$U_2 = [u_{r+1} \ u_{r+2} \ \dots \ u_m]$$

$$\therefore U = [U_1 \ U_2]$$

$$(5) \quad A = U \Sigma V^T$$

· 实际应用中 SVD 是通过求 $A^T A$ 特征值进行的，但不直接计算 $A^T A$.

1.3 实际应用的奇异值分解与矩阵近似

1.3.1 Frobenius norm

定义 1.4: $A \in \mathbb{R}^{m \times n}$,

$$\|A\|_F = \left(\sum_{i=1}^m \sum_{j=1}^n (a_{ij})^2 \right)^{\frac{1}{2}}$$

引理 1.1: $A = U \Sigma V^T$, $\Sigma = \text{diag}(b_1, b_2, \dots, b_n)$

$$\text{则 } \|A\|_F = (b_1^2 + b_2^2 + \dots + b_n^2)^{\frac{1}{2}}$$

证明: 若 Q 为 m 阶正交矩阵, 则有

$$\|QA\|_F = \|A\|_F$$

$$\begin{aligned} \text{因为 } \|QA\|_F^2 &= \|(Qa_1, Qa_2, \dots, Qa_n)\|_F^2 \\ &= \sum_{i=1}^n \|Qa_i\|_2^2 = \sum_{i=1}^n \|a_i\|_2^2 = \|A\|_F^2 \end{aligned}$$

同样, 若 P 为 n 阶正交矩阵, 则有

$$\|AP^T\|_F = \|A\|_F$$

$$\text{故 } \|A\|_F = \|U \Sigma V^T\|_F = \|\Sigma\|_F$$

1.3.2 矩阵的最优近似

定理 1.2: $A \in \mathbb{R}^{m \times n}$, $\text{rank}(A) = r$, 设 M 为 $\mathbb{R}^{m \times n}$ 中所有秩不超过 k 的矩阵集合, $0 < k < r$, 则存在一个秩为 k 的矩阵 $X \in M$, 使得

$$\|A - X\|_F = \min_{S \in M} \|A - S\|_F$$

称矩阵 X 为 A 在 Frobenius norm 下的最优近似

定理 1.3：若秩为 k 的 $X \in M$ ，满足

$$\|A - X\|_F = \min_{S \in M} \|A - S\|_F$$

$$\text{则 } \|A - X\|_F = (\sigma_{k+1}^2 + \sigma_{k+2}^2 + \dots + \sigma_n^2)^{\frac{1}{2}}$$

特别地，若 $A' = U\Sigma'V^T$ ，其中

$$\Sigma' = \begin{bmatrix} \sigma_1 & & & 0 \\ & \ddots & & \\ & & \sigma_k & 0 \\ 0 & & & \ddots & 0 \end{bmatrix} = \begin{bmatrix} \Sigma_k & 0 \\ 0 & 0 \end{bmatrix}$$

$$\text{则 } \|A - A'\|_F = (\sigma_{k+1}^2 + \sigma_{k+2}^2 + \dots + \sigma_n^2)^{\frac{1}{2}} = \min_{S \in M} \|A - S\|_F$$

证明：由于 $\|A - X\|_F \leq \|A - A'\|_F = (\sigma_{k+1}^2 + \sigma_{k+2}^2 + \dots + \sigma_n^2)^{\frac{1}{2}}$

$$\text{下面证明 } \|A - X\|_F \geq (\sigma_{k+1}^2 + \sigma_{k+2}^2 + \dots + \sigma_n^2)^{\frac{1}{2}}$$

设 $X = Q\Omega P^T$ ，其中

$$\Omega = \begin{bmatrix} w_1 & & & 0 \\ & \ddots & & \\ & & w_k & 0 \\ 0 & & & \ddots & 0 \end{bmatrix} = \begin{bmatrix} \Omega_k & 0 \\ 0 & 0 \end{bmatrix}$$

若 $B = Q^TAP$ ，则 $A = QB P^T$ ，

$$\Rightarrow \|A - X\|_F = \|Q(B - \Omega)P^T\|_F = \|B - \Omega\|_F$$

用 Ω 分块方法对 B 分块

$$B = \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix}$$

其中 B_{11} 为 $k \times k$ 子矩阵

$$\Rightarrow \|A - X\|_F^2 = \|B - \Omega\|_F^2 = \|B_{11} - \Omega_k\|_F^2 + \|B_{12}\|_F^2 + \|B_{21}\|_F^2 + \|B_{22}\|_F^2$$

用反证法证 $B_{12}, B_{21} = 0$:

$$\text{若 } B_{12} \neq 0, \text{ 令 } Y = Q \begin{bmatrix} B_{11} & B_{12} \\ 0 & 0 \end{bmatrix} P^T$$

$$\text{则 } Y \in M, \text{ 且 } \|A - Y\|_F^2 = \|B_{21}\|_F^2 + \|B_{22}\|_F^2 < \|A - X\|_F^2$$

\Rightarrow 矛盾 $\Rightarrow B_{12} = 0$, 同理 $B_{21} = 0$

$$\Rightarrow \|A - X\|_F^2 = \|B_{11} - \Omega_k\|_F^2 + \|B_{22}\|_F^2$$

再证 $B_{11} = \Omega_k$. 为此令

$$Z = Q \begin{bmatrix} B_{11} & 0 \\ 0 & 0 \end{bmatrix} P^T \in M$$

$$\|A - Z\|_F^2 = \|B_{22}\|_F^2 \leq \|B_{11} - \Omega_k\|_F^2 + \|B_{22}\|_F^2 = \|A - X\|_F^2$$

$$\Rightarrow \|B_{11} - \Omega_k\|_F^2 = 0 \Rightarrow B_{11} = \Omega_k$$

最后看 B_{22} . 若 $(m-k) \times (n-k)$ 的 $B_{22} = U_1 \Lambda V_1^T$, 则

$$\|A - X\|_F = \|B_{22}\|_F = \|\Lambda\|_F$$

证明 Λ 的对角元素为 A 的奇异值. 为此, 令

$$U_2 = \begin{bmatrix} \mathbb{1}_k & 0 \\ 0 & U_1 \end{bmatrix}, \quad V_2 = \begin{bmatrix} \mathbb{1}_k & 0 \\ 0 & V_1 \end{bmatrix}$$

U_2, V_2 的分块与 B 的分块一致. 注意 B 及 B_{22} 的 SVD

$$U_2^T Q^T A P V_2 = \begin{bmatrix} \Omega_k & 0 \\ 0 & \Lambda \end{bmatrix}$$

$$A = (Q U_2) \begin{bmatrix} \Omega_k & 0 \\ 0 & \Lambda \end{bmatrix} (P V_2)^T$$

由 Λ 的对角元素为 A 的奇异值, 故有

$$\|A - X\|_F = \|\Lambda\|_F \geq (b_{k+1}^2 + b_{k+2}^2 + \dots + b_n^2)^{\frac{1}{2}}$$

$$\Rightarrow \|A - X\|_F = (\sigma_{k+1}^2 + \sigma_{k+2}^2 + \dots + \sigma_n^2)^{\frac{1}{2}} = \|A - A'\|_F$$

以上定理表明，在秩不超过 k 的 $m \times n$ 的矩阵集合中，存在矩阵 A 的 Frobenius norm 意义下的最优近似矩阵 X 。 $A' = U\Sigma'V^T$ 是达到最优值的一个矩阵。

1.3.3 矩阵的外积展开式

- $U\Sigma = [\sigma_1 u_1 \ \sigma_2 u_2 \ \dots \ \sigma_n u_n]$

$$V^T = \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_n^T \end{bmatrix}$$

则 $A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots + \sigma_n u_n v_n^T$

称为 A 的外积展开式，其中 $u_k v_k^T$ 为 $m \times n$ 矩阵，为列向量 u_k 和行向量 v_k^T 的外积。

$$u_i v_j^T = \begin{bmatrix} u_{1i} \\ u_{2i} \\ \vdots \\ u_{ni} \end{bmatrix} [v_{1j} \ v_{2j} \ \dots \ v_{nj}] = \begin{bmatrix} u_{1i} v_{1j} & u_{1i} v_{2j} & \dots & u_{1i} v_{nj} \\ u_{2i} v_{1j} & u_{2i} v_{2j} & \dots & u_{2i} v_{nj} \\ \vdots & \vdots & \ddots & \vdots \\ u_{ni} v_{1j} & u_{ni} v_{2j} & \dots & u_{ni} v_{nj} \end{bmatrix}$$

A 的外积展开式也可写成

$$A = \sum_{k=1}^n A_k = \sum_{k=1}^n \sigma_k u_k v_k^T$$

其中 $A_k = \sigma_k u_k v_k^T$ 是 $m \times n$ 矩阵

由以上知，若 A 的秩为 n ，则

$$A = \sigma_1 u_1 v_1^T + \dots + \sigma_n u_n v_n^T$$

一般地，设矩阵 $A_k = \sigma_1 U_1 V_1^T + \sigma_2 U_2 V_2^T + \dots + \sigma_k U_k V_k^T$
则 A_k 的秩为 k ，且 A_k 是秩为 k 的矩阵中在 Frobenius norm
意义下 A 的最优近似矩阵。 A_k 为 A 的截断 SVD

- 通常 σ_i 递减很快，所以 k 取值很小时， A_k 对 A 也有很好的近似